UNIVERSIDAD EAFIT

Tópicos Especiales en Telemática Laboratorio 3-3

Juan Manuel Gómez - Ingeniería de Sistemas (jmgomezp@eafit.edu.co)

Profesor: Edwin Nelson Montoya

Procesamiento del dataset Casos_positivos_de_COVID-19_en_Colombia-100K.csv usando PySpark en Google Colab

En esta ocasión se hizo una exploración de los datos referentes a los casos de COVID-19 en Colombia con los datos proporcionados por el Ministerio de Salud. Luego de haber hecho todo el procesamiento se subieron los archivos al Bucket de S3.

En este caso se desarrollaron los siguientes puntos:

- Columnas.
- Tipos de datos.
- Seleccionar algunas columnas.
- Renombrar columnas.
- Agregar columnas.
- Borrar columnas.
- Filtrar datos.
- Ejecutar alguna función UDF sobre alguna columna creando una nueva.
- Ejecutar una función lambda sobre alguna columna creando una nueva.

En este caso se utilizó un Notebook de Google Colab con PySpark. Dentro del repositorio de GitHub se encuentra el Notebook (covid_data_processing_using_pyspark_colab.ipynb) con los resultados de este laboratorio

Output en el Bucket de S3





